

Pregunta2

Luis Llera García


1 de febrero de 2019

Series Temporales El objetivo del siguiente informe será realizar la predicciones semanales y mensuales de agosto de 2018, mediante los modelos ARIMA y ETS. En la que se explicaba que se había producido una caída del turismo en Lanzarote en el verano del 2017, y con ello lo que se pretende es identificar y si diera tiempo reconducir dicho impacto. Primeramente vamos a realizar la predicción semanal, por tanto tenemos que pasar los datos a semanales para trabajar con ellos, y comprobamos el tipo de serie que es, como se produce un aumento claro en la serie temporal pero vuelve a su estado inicial podremos afirmar que es un impulso.

Primeramente hemos tratado las variables con el paquete zoo, y representamos una primera aproximación.

```
autoplot(zWeeklyData) + geom_point() +  
  ylab("Ventas") + ggtitle("Cuota semanal") + xlab("Semanas") +  
  ggtitle('Representacion semanal')
```

Representacion semanal




Más tarde, establecemos el numero de observaciones que que hemos omitir, cOmit, como no tenemos los datos del mes de agosto debemos de trabajar con la serie al completo.

```
autoplot(zMonthlyData) + geom_point() +  
  ylab("Ventas") + ggtitle("Cuota mensual") + xlab("Semanas") +  
  ggtitle('Representacion mensual')
```


```
## Don't know how to automatically pick scale for object of type yearmon. Defaulting to continuous.
```

Representacion mensual



ARIMA De la misma manera pasa con los datos mensuales la diferencia es que esta si que tiene, sobre todo, un outlier significativo y es un impulso por que vuelve al estado original. Se va a realizar a continuación una primera aproximación por el modelo ARIMA. Ahora con la función `auto.arima` elegiremos los mejores modelos tanto para mensual como para semanal, teniendo en cuenta el criterio de menor AIC, para la semanal nos arroja un modelo $ARIMA(0,1,0)$. Y para el mensual $ARIMA(2,0,2)(2,0,0)[12]$ with non-zero mean. Como el de las semanales no tiene componente estacional, debemos de utilizar el ETS, para los semanales, y como el mensual si que tiene pues le aplicaremos un modelo Después realizamos La prueba de Ljung-Box que es un tipo de prueba estadística de si un grupo cualquiera de autocorrelaciones de una serie de tiempo son diferentes de cero, por tanto si hacemos ese test de los residuos, por tanto buscamos aceptar la hipótesis nula de que los residuos son ruido blanco y no nos influyen en el modelo. Al comprobarlo con 4 lags, nos arroja un p-valor muy alto, por encima del 0.05 por tanto son ruido blanco. Gráficamente se ve perfecto. Si se encuentran dentro de las bandas azules son ruido blanco, como nos ocurre a nosotros


```
ggtsdisplay(fit.mensual$residuals)
```



Ahora observamos el Forecast del mensua, con un modelo arima, es decir, la precci3n, las bandas azules indican por donde puede fluctuar la serie como podemos observar tiene unas bandas bastante amplias.

```
plot(fmensual.arima)
```

Forecasts from ARIMA(2,0,2)(2,0,0)[12] with non-zero mean



ETS Ahora realizamos el modelo ets con el mensual y el semanal.

etsfit # nuestro modelo semanal: ETS(A,N,N) error aditivo, tendencia ninguna, componente estacional nin

```
## ETS(A,N,N)
##
## Call:
## ets(y = oVentasWeekly, ic = "aic")
##
## Smoothing parameters:
##   alpha = 0.2
##
## Initial states:
##   l = 1532
##
## sigma: 581.9489
```

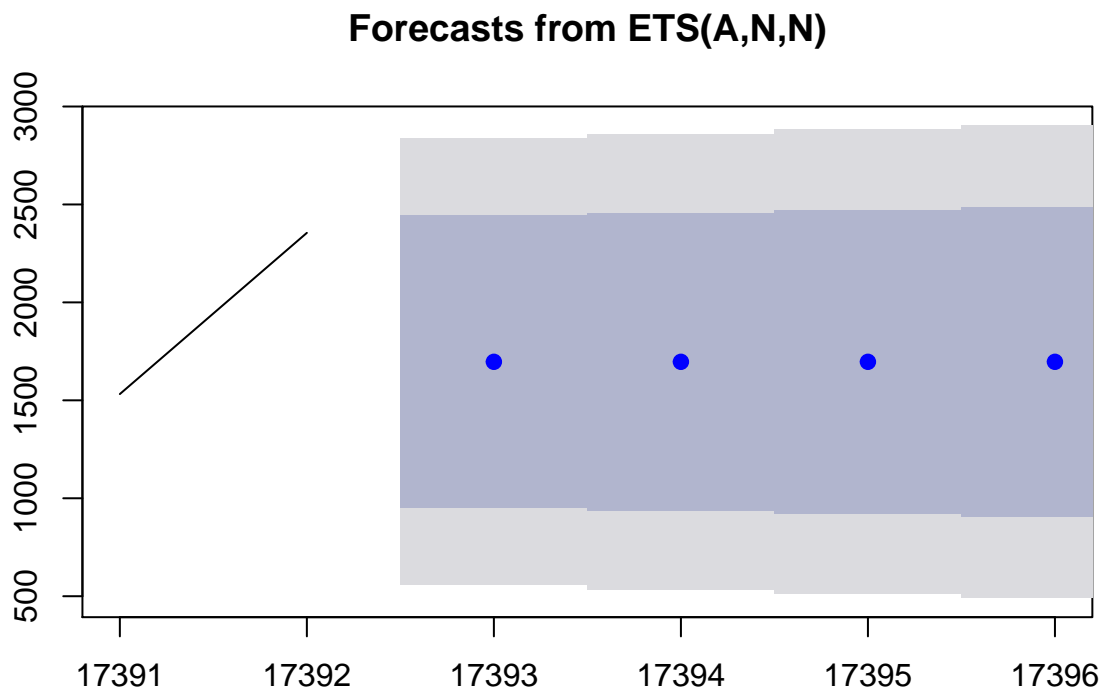
etsfit2 # nuestro modelo mensual: ETS(M,N,M) error multiplicativo, tendencia ninguna, componente estaci

```
## ETS(M,N,M)
##
## Call:
## ets(y = oVentasMonthly, ic = "aic")
##
## Smoothing parameters:
##   alpha = 1e-04
##   gamma = 1e-04
##
```

```
## Initial states:
## l = 1518.8527
## s = 0.836 0.8312 1.0531 1.0355 1.2239 1.3848
##      0.9953 0.7832 0.9248 1.1039 1.0407 0.7876
##
## sigma: 0.3316
##
##      AIC      AICc      BIC
## 1988.399 1993.248 2029.573
```


Como podemos observar nuestro modelo semanal ETS ,ETS(A,N,N), nos indica que no tiene tendencia ni componente estacional, a diferencia del mensual, ETS(M,N,M), que tiene error multiplicativo, sin tendencia y con un componente estacional multiplicativo.

```
plot(fsemanal.ets) # malas predicciones
```



```
plot(fmensual.ets)
```

Forecasts from ETS(M,N,M)



Como podemos observar las predicciones semanales son bastante malas por tanto las desechamos, pero de las mensuales, como podemos observar, se parece mucho al forecast que hemos realizado anteriormente, son buenas predicciones.

```
summary(fsemanal.ets) # Los resultados de las predicciones y sus intervalos de confianza
```

```
##
## Forecast method: ETS(A,N,N)
##
## Model Information:
## ETS(A,N,N)
##
## Call:
## ets(y = oVentasWeekly, ic = "aic")
##
## Smoothing parameters:
##   alpha = 0.2
##
## Initial states:
##   l = 1532
##
## sigma: 581.9489
## Error measures:
##           ME      RMSE   MAE      MPE      MAPE  MASE  ACF1
## Training set 411.5 581.9489 411.5 17.47346 17.47346 0.5 -0.5
##
## Forecasts:
```

```
##      Point Forecast    Lo 80    Hi 80    Lo 95    Hi 95
## 17393      1696.6 950.8026 2442.398 556.0013 2837.199
## 17394      1696.6 936.0329 2457.167 533.4129 2859.787
## 17395      1696.6 921.5446 2471.656 511.2550 2881.945
## 17396      1696.6 907.3222 2485.878 489.5037 2903.697
```

```
summary(fmensual.ets)
```

```
##
## Forecast method: ETS(M,N,M)
##
## Model Information:
## ETS(M,N,M)
##
## Call:
## ets(y = oVentasMonthly, ic = "aic")
##
## Smoothing parameters:
##   alpha = 1e-04
##   gamma = 1e-04
##
## Initial states:
##   l = 1518.8527
##   s = 0.836 0.8312 1.0531 1.0355 1.2239 1.3848
##       0.9953 0.7832 0.9248 1.1039 1.0407 0.7876
##
## sigma: 0.3316
##
##      AIC      AICc      BIC
## 1988.399 1993.248 2029.573
##
## Error measures:
##           ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 40.13035 483.2497 394.7945 -10.73763 32.42729 0.8787999
##           ACF1
## Training set -0.1044071
##
## Forecasts:
##      Point Forecast    Lo 80    Hi 80    Lo 95    Hi 95
## Aug 2018      1859.476 1069.202 2649.749 650.8566 3068.094
```

```
tail(zMonthlyData,25)
```

```
##      Mensual
## jul. 2016    1203
## ago. 2016    2337
## sep. 2016    1804
## oct. 2016    1180
## nov. 2016    1325
## dic. 2016    1089
## ene. 2017    2135
## feb. 2017    2442
## mar. 2017    1723
## abr. 2017    1365
## may. 2017    1484
```

## jun. 2017	2034
## jul. 2017	2190
## ago. 2017	2355
## sep. 2017	1824
## oct. 2017	2205
## nov. 2017	2135
## dic. 2017	929
## ene. 2018	1445
## feb. 2018	2079
## mar. 2018	1970
## abr. 2018	1451
## may. 2018	1446
## jun. 2018	1849
## jul. 2018	950

Y por último podemos observar la evolución de los valores de Julio, de 2000 como mínimo ha bajado a un 950, por tanto la predicción de crecimiento es básicamente negativa. Si comparamos los valores de junio y julio de 2018 (1849 y 950) se estima un valor de 1859.